

Relatório: Classificação da Qualidade de Vinhos com Machine Learning

Alex Martins & Adler Las-Cazas
POSTECH - DTAT - FASE 2

Resumo

Este relatório apresenta uma solução analítica para antecipar a classificação de qualidade de vinhos Vinho Verde a partir de variáveis físico-químicas. A abordagem transforma a avaliação sensorial original em um problema de classificação binária, permitindo apoiar decisões de produção, controle de qualidade e ajustes de blend com base em evidências quantitativas. O modelo final selecionado foi o Random Forest, com acurácia final de 79,07%, destacando álcool, sulfatos e acidez volátil como os principais direcionadores de qualidade.

1. Compreensão do Problema e Contexto de Negócio

O objetivo do projeto é estimar, de forma antecipada, se um vinho tende a alcançar um patamar superior de qualidade a partir de medições laboratoriais. Na prática, isso permite que a vinícola identifique riscos de qualidade antes da etapa final de avaliação sensorial, reduzindo desperdícios, apoiando correções de processo e aumentando a consistência do produto.

Para tornar a decisão mais acionável, a escala original de qualidade foi convertida em duas classes operacionais:

- **Vinho de Alta Qualidade (Bom):** nota ≥ 6
- **Vinho de Baixa/Média Qualidade (Abaixo da Média/Ruim):** nota < 6

2. Análise Exploratória de Dados (EDA)

A análise exploratória avaliou a distribuição das variáveis, o balanceamento das classes e as relações entre os atributos físico-químicos. O conjunto de dados Wine Quality, da UCI Machine Learning Repository, contém amostras de vinhos Vinho Verde portugueses e permite tarefas de classificação ou regressão com base em 11 variáveis laboratoriais e uma nota de qualidade sensorial.


2.1. Investigação da Distribuição das Variáveis

Análise univariada realizada para compreender a dispersão, assimetria e o comportamento de atributos fundamentais como acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico.

	count	mean	std	min	25%	50%	75%	max
fixed acidity	1143.0	8.311111	1.747595	4.60000	7.10000	7.90000	9.100000	15.900
volatile acidity	1143.0	0.531339	0.179633	0.12000	0.39250	0.52000	0.640000	1.580
citric acid	1143.0	0.268364	0.196686	0.00000	0.09000	0.25000	0.420000	1.000
residual sugar	1143.0	2.532152	1.355917	0.90000	1.90000	2.20000	2.600000	15.500
chlorides	1143.0	0.086933	0.047267	0.01200	0.07000	0.07900	0.090000	0.611
free sulfur dioxide	1143.0	15.615486	10.250486	1.00000	7.00000	13.00000	21.000000	68.000
total sulfur dioxide	1143.0	45.914698	32.782130	6.00000	21.00000	37.00000	61.000000	289.000
density	1143.0	2.258444	9.793424	0.99007	0.99557	0.99668	0.997845	100.369
pH	1143.0	3.311015	0.156664	2.74000	3.20500	3.31000	3.400000	4.010
sulphates	1143.0	0.657708	0.170399	0.33000	0.55000	0.62000	0.730000	2.000
alcohol	1143.0	10.442248	1.082000	8.40000	9.50000	10.20000	11.100000	14.900
target	1143.0	0.543307	0.498339	0.00000	0.00000	1.00000	1.000000	1.000


2.2. Análise do Balanceamento de Classes

Avaliação quantitativa da proporção entre as categorias geradas, identificando o severo desbalanceamento natural que caracteriza este mercado, onde apenas uma fração minoritária das amostras atinge o patamar de excelência (nota ≥ 6).



2.3. Identificação e Justificativa de Correlações

Construção e avaliação da matriz de correlação estatística para identificar dependências lineares entre as propriedades do vinho, avaliando o impacto direto e indireto de cada componente químico sobre o veredito final da qualidade.



3. Pré-processamento de Dados e modelagem

O pré-processamento estruturou a base para comparação entre três abordagens de classificação: Logistic Regression, Random Forest e K-Nearest Neighbors. As etapas priorizaram consistência estatística, comparabilidade entre variáveis e redução de viés decorrente do desbalanceamento de classes.

- **Tratamento de Dados Faltantes:** Verificação e tratamento de valores nulos (se existentes na base).
- **Padronização de Variáveis Numéricas:** Aplicação de escala via StandardScaler para unificar a magnitude das variáveis para modelos baseados em distâncias métricas.
- **Criação de Novas Features e Balanceamento:** Aplicação da técnica de sobreamostragem sintética (SMOTE) para mitigar o vício estatístico causado pelo desbalanceamento das classes.


3.1. Desenvolvimento de Modelos de Classificação


Treinamento comparativo estruturado sob 3 metodologias de classificação com filosofias matemáticas distintas para a predição da qualidade:

- **K-Nearest Neighbors (KNN):** Algoritmo baseado em proximidade geométrica e distância euclidiana.
- **Random Forest:** Modelo de comitê baseado em múltiplas árvores de decisão trabalhando de forma não-linear.
- **Logistic Regression:** algoritmo de classificação que prevê um resultado discreto ou categórico. .

4. Avaliação Comparativa dos Modelos e Interpretação dos Resultados

Após treinamento dos 3 modelos, as métricas de todos os classificadores são confrontadas e analisadas:





Resultado-chave: o Random Forest apresentou o melhor desempenho comparativo, com acurácia de 79,91% antes do refinamento. A escolha é consistente com sua capacidade de capturar relações não lineares e medir a importância relativa das variáveis no processo decisório.

Álcool: principal fator associado à qualidade, indicando a importância do controle de maturação da uva e da fermentação.


Sulfatos: variável relevante para conservação e estabilidade do vinho, reforçando a necessidade de controle técnico na adição de compostos sulfurosos.

Acidez volátil: indicador crítico de deterioração potencial; níveis elevados podem sinalizar falhas sanitárias ou fermentativas que afetam a percepção de qualidade.

5. Refinamento do Modelo e Algoritmo Final

5.1. Detecção de Outliers e Valores Inconsistentes

Uso de técnicas como Interquartile Range (IQR) para isolar picos ou desvios químicos severos na amostra que possam comprometer a convergência adequada dos estimadores numéricos.



5.1. Modelo de Produção Final

Após a limpeza dos dados e o refinamento do pipeline, o Random Forest foi retreinado como modelo final de produção. A acurácia final foi de 79,07%, mantendo desempenho consistente e fornecendo maior interpretabilidade para apoiar decisões operacionais.

Acurácia Pós-Tratamento de Outliers: 79.07%

Relatório de Produção:

	precision	recall	f1-score	support
0	0.80	0.71	0.75	97
1	0.78	0.86	0.82	118
accuracy			0.79	215
macro avg	0.79	0.78	0.79	215
weighted avg	0.79	0.79	0.79	215

6. Implicações para a Indústria e Recomendações

A adoção do modelo no processo produtivo pode transformar o controle de qualidade em uma rotina preditiva. Em vez de depender apenas da avaliação final, a vinícola passa a contar com um sistema de alerta baseado em dados laboratoriais, capaz de orientar ajustes preventivos, priorizar lotes com maior potencial e apoiar decisões de blend para corrigir perfis físico-químicos indesejados.

- **Recomendação 1:** monitorar continuamente álcool, sulfatos e acidez volátil como indicadores prioritários de qualidade.
- **Recomendação 2:** utilizar o modelo como apoio à decisão, não como substituto da avaliação enológica e sensorial.

- **Recomendação 3:** validar o modelo periodicamente com novos lotes para preservar desempenho e aderência ao processo produtivo.